

科研训练汇报

数学强基 2202 陈宇昂

西安交通大学数学与统计学院

2025 年 6 月 23 日



- ① Diffusion Model
- ② Flow Matching
- ③ Score-Based Model

DDPM

DDIM

相关应用

DDPM

模型简述

数学原理

实验结果

DDIM

相关应用

② Flow Matching

③ Score-Based Model

核心思想：DDPM 模型¹利用了一种参数化的 Markov 链，通过变分推理训练，在有限时间内生成与数据匹配的样本。




Figure 2: The directed graphical model considered in this work.

图 1: DDPM 模型示意图

该 Markov 链包含前向过程(forward process) 和反向过程(reverse process)。

- 前向过程即在图像上不断添加噪声，直至图像成为纯噪声；
- 反向过程即在纯噪声上生成一张图像。

¹Ho, Jonathan, et al. "Denoising Diffusion Probabilistic Models." NeurIPS 2020, <https://arxiv.org/abs/2006.11239>.

100%

前向过程 (Forward Process) 的作用是给图像加上噪声。

- 给定初始数据分布 $x \sim q(x)$ ，可以不断地向分布中添加高斯噪声，该噪声的标准差是以固定值 β_t 而确定的，均值是以固定值 β_t 和当前 t 时刻的数据 x_t 决定的。上述过程是一个 Markov 过程。
- 随着 t 的不断增大，最终数据分布 x_T 变成了一个各向独立的高斯分布。

$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) := \prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1}), \quad q(\mathbf{x}_t|\mathbf{x}_{t-1}) := \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I})$$

- 其中, $\beta_t \in (0, 1)$, $\{\beta_t\}$ 是单增的
- 上述各数均已知, 不含未知参数。

上式左侧为联合分布，右侧用于计算 x_t 分布，得到采样值。从 β_t 可以看出，前向加噪越加越块。

无需迭代的计算方法

记 $\alpha_t := 1 - \beta_t$, $\bar{\alpha}_t := \prod_{s=1}^t \alpha_s$
计算

$$\begin{aligned}
 \mathbf{x}_t &= \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \epsilon_{t-1} \\
 &= \sqrt{\alpha_t} \left(\sqrt{\alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{1 - \alpha_{t-1}} \epsilon_{t-2} \right) + \sqrt{1 - \alpha_t} \epsilon_{t-1} \\
 &= \sqrt{\alpha_t \alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{\alpha_t - \alpha_t \alpha_{t-1}} \epsilon_{t-2} + \sqrt{1 - \alpha_t} \epsilon_{t-1} \\
 &= \sqrt{\alpha_t \alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{1 - \alpha_t \alpha_{t-1}} \epsilon'_{t-2}, \quad \epsilon'_{t-2} \sim \mathcal{N}(0, \mathbf{I}) \\
 &= \cdots = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon_0, \quad \epsilon_i \sim \mathcal{N}(0, \mathbf{I})
 \end{aligned} \tag{1}$$

得到

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

- 其中, $\bar{\alpha}_t \in (0, 1)$, $\{\bar{\alpha}_t\}$ 是单减的。

利用上式还可以用于计算 T 的大小 (利用让 $\mathbf{x}_T$ 近似服从 $\mathcal{N}(0, \mathbf{I})$ 来估计 T)

后验条件概率 $q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}(\mathbf{x}_t, \mathbf{x}_0), \tilde{\boldsymbol{\beta}}_t \mathbf{I})$ 的推导

由 Bayes 公式与 Markov 过程的假设,

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0) = q(\mathbf{x}_t \mid \mathbf{x}_{t-1}) \sim \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}) = \mathcal{N}(\mathbf{x}_t; \sqrt{\alpha_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_0) \sim \mathcal{N}(\mathbf{x}_{t-1}; \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0, (1 - \bar{\alpha}_{t-1}) \mathbf{I})$$

$$q(\mathbf{x}_t \mid \mathbf{x}_0) \sim \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

于是,

$$\begin{aligned} q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) &= q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0) \frac{q(\mathbf{x}_{t-1} \mid \mathbf{x}_0)}{q(\mathbf{x}_t \mid \mathbf{x}_0)} \\ &\propto \exp \left(-\frac{1}{2} \left(\frac{(\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_{t-1})^2}{\beta_t} + \frac{(\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \mathbf{x}_0)^2}{1 - \bar{\alpha}_t} \right) \right) \\ &= \exp \left(-\frac{1}{2} \left(\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \mathbf{x}_{t-1}^2 - \left(\frac{2\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{2\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) \mathbf{x}_{t-1} + C(\mathbf{x}_t, \mathbf{x}_0) \right) \right) \\ &\propto \exp \left(-\frac{1}{2} \left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \left(\mathbf{x}_{t-1} - \frac{\left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right)^2}{\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right)} \right)^2 \right) \end{aligned}$$

可得,

$$\tilde{\boldsymbol{\beta}}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t, \quad \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0 \quad (2)$$

参数重整化

由式1, 得到

$$\mathbf{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} (\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_t)$$

带入式2中,

$$\begin{aligned} \tilde{\mu}_t &= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \cdot \frac{1}{\sqrt{\bar{\alpha}_t}} (\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_t) \\ &= \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_t \right) \end{aligned}$$

- 其中, ϵ_t 是 t 时刻从正态分布中采样的随机值。

© 2006 The Authors
Journal compilation © 2006 Blackwell Publishing Ltd

$$\begin{aligned}
-\log p_{\theta}(\mathbf{x}_0) &\leq -\log p_{\theta}(\mathbf{x}_0) + D_{\text{KL}}(q(\mathbf{x}_{1:T} \mid \mathbf{x}_0) \parallel p_{\theta}(\mathbf{x}_{1:T} \mid \mathbf{x}_0)) \\
&= -\log p_{\theta}(\mathbf{x}_0) + \mathbb{E}_{\mathbf{x}_{1:T} \sim q(\mathbf{x}_{1:T} \mid \mathbf{x}_0)} \left[\log \frac{q(\mathbf{x}_{1:T} \mid \mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{1:T} \mid \mathbf{x}_0)} \right] \\
&= -\log p_{\theta}(\mathbf{x}_0) + \mathbb{E}_{\mathbf{x}_{1:T} \sim q(\mathbf{x}_{1:T} \mid \mathbf{x}_0)} \left[\log \frac{q(\mathbf{x}_{1:T} \mid \mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{0:T}) / p_{\theta}(\mathbf{x}_0)} \right] \\
&= -\log p_{\theta}(\mathbf{x}_0) + \mathbb{E}_q \left[\log \frac{q(\mathbf{x}_{1:T} \mid \mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{0:T})} + \log p_{\theta}(\mathbf{x}_0) \right] \\
&= \mathbb{E}_q \left[\log \frac{q(\mathbf{x}_{1:T} \mid \mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{0:T})} \right]
\end{aligned}$$

最小化右侧式子即可最小化左侧式子，进而最大化似然。

似然函数的推导

两侧同时乘以 $q(\mathbf{x}_0)$ 再积分,

$$\begin{aligned}
 -\mathbb{E}_{q(\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0)] &= - \int q(\mathbf{x}_0) \log p_\theta(\mathbf{x}_0) d\mathbf{x}_0 \\
 &\leq - \int q(\mathbf{x}_0) q(\mathbf{x}_{1:T}) \log \frac{q(\mathbf{x}_{1:T} | \mathbf{x}_0)}{p_\theta(\mathbf{x}_{0:T})} d\mathbf{x}_0 \\
 &\leq - \int q(\mathbf{x}_{0:T}) \log \frac{q(\mathbf{x}_{1:T} | \mathbf{x}_0)}{p_\theta(\mathbf{x}_{0:T})} d\mathbf{x}_0 \\
 &= \mathbb{E}_{q(\mathbf{x}_{0:T})} \left[\log \frac{q(\mathbf{x}_{1:T} | \mathbf{x}_0)}{p_\theta(\mathbf{x}_{0:T})} \right] := L
 \end{aligned}$$

似然函数的推导

$$\begin{aligned}
 L &= \mathbb{E}_q \left[-\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \right] = \mathbb{E}_q \left[-\log \frac{p_\theta(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{\prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})} \right] \\
 &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) - \sum_{t=1}^T \log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_t | \mathbf{x}_{t-1})} \right] \\
 &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) - \sum_{t=2}^T \log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_t | \mathbf{x}_{t-1})} - \log \frac{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)}{q(\mathbf{x}_1 | \mathbf{x}_0)} \right] \\
 &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) - \sum_{t=2}^T \log \left(\frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)} \cdot \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)} \right) - \log \frac{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)}{q(\mathbf{x}_1 | \mathbf{x}_0)} \right] \\
 &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) - \sum_{t=2}^T \log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)} - \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{q(\mathbf{x}_T | \mathbf{x}_0)} - \log p_\theta(\mathbf{x}_0 | \mathbf{x}_1) \right] \\
 &= \mathbb{E}_{q(\mathbf{x}_T | \mathbf{x}_0)} \left[-\log \frac{p_\theta(\mathbf{x}_T)}{q(\mathbf{x}_T | \mathbf{x}_0)} \right] - \mathbb{E}_{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \left[\sum_{t=2}^T \log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)} \right] - \mathbb{E}_{q(\mathbf{x}_1 | \mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)] \\
 &= D_{\text{KL}}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T)) - \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_{t-1}, \mathbf{x}_t | \mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)} \right] - \mathbb{E}_{q(\mathbf{x}_1 | \mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)] \\
 &= \underbrace{D_{\text{KL}}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T))}_{L_T} + \sum_{t=2}^T \underbrace{\mathbb{E}_{q(\mathbf{x}_t | \mathbf{x}_0)} [D_{\text{KL}}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \| p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t))]}_{L_{t-1}} - \underbrace{\mathbb{E}_{q(\mathbf{x}_1 | \mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)]}_{L_0}
 \end{aligned} \tag{3}$$

前向过程与 L_T

式3的第一项 L_T 为常数。

$$L_T = D_{\text{KL}}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T))$$

- $q(\mathbf{x}_T | \mathbf{x}_0)$ 分布是不含参的，可以直接由 α_t 给出；
- $p_\theta(\mathbf{x}_T)$ 是高斯分布。

反向过程与 L_{t-1}

式3的第二项 L_{t-1} 含有参数。

$$L_{t-1} = \mathbb{E}_{q(\mathbf{x}_t | \mathbf{x}_0)} \left[D_{\text{KL}}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)) \right]$$

由式2结合论文中对 $p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 的协方差阵的设置,

$$\Sigma_{\theta}(\mathbf{x}_t, t) = \sigma_t^2 \mathbf{I} = \tilde{\beta}_t \mathbf{I} = \Sigma_q(t)$$

可以得到两个高斯分布

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \sim \mathcal{N}(\mathbf{x}_{t-1}; \mu_q(\mathbf{x}_t, \mathbf{x}_0), \Sigma_q(t))$$

$$p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) \sim \mathcal{N}(\mathbf{x}_{t-1}; \mu_{\theta}(\mathbf{x}_t, t), \Sigma_{\theta}(\mathbf{x}_t, t))$$

所以参数仅存在于第二项的均值中，可以计算其 KL 散度。

对于两高斯分布，其 KL 散度为 (d 表示维数)

$$D_{\text{KL}}(\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_x, \boldsymbol{\Sigma}_x) \parallel \mathcal{N}(\mathbf{y}; \boldsymbol{\mu}_y, \boldsymbol{\Sigma}_y)) = \frac{1}{2} \left[\log \frac{|\boldsymbol{\Sigma}_y|}{|\boldsymbol{\Sigma}_x|} - d + \text{tr}(\boldsymbol{\Sigma}_y^{-1} \boldsymbol{\Sigma}_x) + (\boldsymbol{\mu}_y - \boldsymbol{\mu}_x)^T \boldsymbol{\Sigma}_y^{-1} (\boldsymbol{\mu}_y - \boldsymbol{\mu}_x) \right]$$

于是，

$$\begin{aligned}
& \arg \min_{\theta} D_{\text{KL}}(q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) \parallel p_{\theta}(\mathbf{x}_{t-1} \mid \mathbf{x}_t)) = \arg \min_{\theta} D_{\text{KL}}(\mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_q, \boldsymbol{\Sigma}_q(t)) \parallel \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_{\theta}, \boldsymbol{\Sigma}_{\theta}(t))) \\
&= \arg \min_{\theta} \frac{1}{2} \left[\log \frac{|\boldsymbol{\Sigma}_q(t)|}{|\boldsymbol{\Sigma}_{\theta}(t)|} - d + \text{tr}(\boldsymbol{\Sigma}_q(t)^{-1} \boldsymbol{\Sigma}_{\theta}(t)) + (\boldsymbol{\mu}_{\theta} - \boldsymbol{\mu}_q)^T \boldsymbol{\Sigma}_q(t)^{-1} (\boldsymbol{\mu}_{\theta} - \boldsymbol{\mu}_q) \right] \\
&= \arg \min_{\theta} \frac{1}{2} \left[\log 1 - d + d + (\boldsymbol{\mu}_{\theta} - \boldsymbol{\mu}_q)^T \boldsymbol{\Sigma}_q(t)^{-1} (\boldsymbol{\mu}_{\theta} - \boldsymbol{\mu}_q) \right] \\
&= \arg \min_{\theta} \frac{1}{2} \left[(\boldsymbol{\mu}_{\theta} - \boldsymbol{\mu}_q)^T \boldsymbol{\Sigma}_q(t)^{-1} (\boldsymbol{\mu}_{\theta} - \boldsymbol{\mu}_q) \right] = \arg \min_{\theta} \frac{1}{2} \left[(\boldsymbol{\mu}_{\theta} - \boldsymbol{\mu}_q)^T (\sigma_t^2 \mathbf{I})^{-1} (\boldsymbol{\mu}_{\theta} - \boldsymbol{\mu}_q) \right] \\
&= \arg \min_{\theta} \frac{1}{2\sigma_t^2} \left[\|\mu_q(\mathbf{x}_t, \mathbf{x}_0) - \mu_{\theta}(\mathbf{x}_t, t)\|_2^2 \right]
\end{aligned}$$

经过上面的推理², 可得

$$L_{t-1} = \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma_t^2} \|\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_\theta(\mathbf{x}_t, t)\|^2 \right] + C \quad (4)$$

²Luo C. Understanding Diffusion Models: A Unified Perspective[J/OL]. arXiv:2208.11970 [cs.LG], 2022.

反向过程与 L_{t-1}

式1的结果代入式4中，并利用式2

$$\begin{aligned}
 L_{t-1} - C &= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \tilde{\mu}_t \left(\mathbf{x}_t(\mathbf{x}_0, \epsilon), \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t(\mathbf{x}_0, \epsilon) - \sqrt{1 - \bar{\alpha}_t} \epsilon \right) \right) - \mu_\theta(\mathbf{x}_t(\mathbf{x}_0, \epsilon), t) \right\|^2 \right] \\
 &= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t(\mathbf{x}_0, \epsilon) + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t(\mathbf{x}_0, \epsilon) - \sqrt{1 - \bar{\alpha}_t} \epsilon \right) - \mu_\theta(\mathbf{x}_t(\mathbf{x}_0, \epsilon), t) \right\|^2 \right] \\
 &= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t(\mathbf{x}_0, \epsilon) + \frac{\beta_t}{1 - \bar{\alpha}_t} \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t(\mathbf{x}_0, \epsilon) - \sqrt{1 - \bar{\alpha}_t} \epsilon \right) - \mu_\theta(\mathbf{x}_t(\mathbf{x}_0, \epsilon), t) \right\|^2 \right] \\
 &= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t(\mathbf{x}_0, \epsilon) - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right) - \mu_\theta(\mathbf{x}_t(\mathbf{x}_0, \epsilon), t) \right\|^2 \right] \quad (5)
 \end{aligned}$$

在训练时 $\mathbf{x}_t$ 作为输入，对上式中的 μ_θ 进行参数重整化，将 ϵ 视作 $\epsilon_\theta(\mathbf{x}_t, t)$

$$\mu_\theta(\mathbf{x}_t, t) = \tilde{\mu}_t \left(\mathbf{x}_t, \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(\mathbf{x}_t, t) \right) \right) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t, t) \right)$$

可将式5右侧进行化简，并结合式1可得，

$$\begin{aligned}
 \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right) - \mu_\theta(\mathbf{x}_t, t) \right\|^2 \right] &= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right) - \mu_\theta(\mathbf{x}_t, t) \right\|^2 \right] \\
 = \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)} \left\| \epsilon - \epsilon_\theta(\mathbf{x}_t, t) \right\|^2 \right] &= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)} \left\| \epsilon - \epsilon_\theta(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right\|^2 \right] \quad (6)
 \end{aligned}$$

反向过程与 L_{t-1}

式6中 ϵ 预测的参数化形式既与 Langevin 动力学类似，又能将扩散模型的变分界简化为类似去噪得分匹配 (denoising score matching) 的目标。论文作者发现，丢掉系数可以使得训练更加稳定，质量更好，因此最终采用了省去权重的损失

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\left\| \epsilon - \epsilon_{\theta} \left(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t \right) \right\|^2 \right]$$

QUESTIONS

Algorithm 2 Sampling

```

1:  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2: for  $t = T, \dots, 1$  do
3:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  if  $t > 1$ , else  $\mathbf{z} = \mathbf{0}$ 
4:    $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\alpha_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$ 
5: end for
6: return  $\mathbf{x}_0$ 

```

References

- ↶ ↷ ↻

1111

DDIM

模型简述

数学原理

实验结果

相关应用

③ Score-Based Model

模型简述

核心思想：DDIM 模型³通过一类非马尔可夫扩散过程对 DDPMs 进行推广，这些非马尔可夫过程可以对应于确定性的生成过程，从而产生能够更快生成高质量样本的隐式模型。




Figure 1: Graphical models for diffusion (left) and non-Markovian (right) inference models.

图 3: DDIM 模型示意图

二者在训练过程上相同，但相较于 DDPM 模型，DDIM 模型具有以下优势：

- 将采样速度提高 10 倍到 100 倍时，DDIMs 的样本生成质量优于 DDPMs；
- DDIM 样本具有以下“一致性”特性，而 DDPMs 不具备：如果我们从相同的初始潜在变量开始，并使用不同长度的马尔可夫链生成多个样本，这些样本将具有相似的高级特征。

³Song, Jiaming, et al. "Denoising Diffusion Implicit Models." ICLR 2021,

<https://arxiv.org/abs/2010.02502>.

DDPM 原理回顾

与 DDPM 类似，可以定义如下用于采样的分布

$$p_{\theta}(\mathbf{x}_0) = \int p_{\theta}(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}, \quad p_{\theta}(\mathbf{x}_{0:T}) := p_{\theta}(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}^{(t)}(\mathbf{x}_{t-1} | \mathbf{x}_t)$$

然后最大化变分下界作为目标函数

$$\max_{\theta} \mathbb{E}_{q(\mathbf{x}_0)} [\log p_{\theta}(\mathbf{x}_0)] \leq \max_{\theta} \mathbb{E}_{q(\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_T)} [\log p_{\theta}(\mathbf{x}_{0:T}) - \log q(\mathbf{x}_{1:T} | \mathbf{x}_0)]$$

下设隐变量的推断分布

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) := \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}), \quad q(\mathbf{x}_t | \mathbf{x}_{t-1}) := \mathcal{N}\left(\sqrt{\frac{\alpha_t}{\alpha_{t-1}}} \mathbf{x}_{t-1}, \left(1 - \frac{\alpha_t}{\alpha_{t-1}}\right) \mathbf{I}\right) \quad (7)$$

- 其中，DDIM 推导过程中的 α_t 与 DDPM 中的 $\bar{\alpha}_t$ 意义相同；
- 协方差矩阵的对角线元素确保为正。

我们将从 $\mathbf{x}_T$ 到 $\mathbf{x}_0$ 进行采样、作为 Markov 链的隐变量模型 $p_{\theta}(\mathbf{x}_{0:T})$ 称为 **生成过程 (generative process)**。直观上，前向过程逐步向观测值 $\mathbf{x}_0$ 添加噪声，而生成过程则逐步对噪声观测值进行去噪。

DDPM 原理回顾

在前向过程中，有性质

$$q(\mathbf{x}_t | \mathbf{x}_0) := \int q(\mathbf{x}_{1:t} | \mathbf{x}_0) d\mathbf{x}_{1:(t-1)} = \mathcal{N}(\mathbf{x}_t; \sqrt{\alpha_t} \mathbf{x}_0, (1 - \alpha_t) \mathbf{I})$$

且可以通过随机变量 ϵ 将 $\mathbf{x}_t$ 与 $\mathbf{x}_0$ 联系起来，

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \epsilon, \quad \text{where } \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (8)$$

当我们将 α_T 设置得足够接近 0 时，对于所有 $\mathbf{x}_0$ ， $q(\mathbf{x}_T | \mathbf{x}_0)$ 会收敛到标准高斯分布，因此自然可以设定 $p_\theta(\mathbf{x}_T) := \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。如果所有条件分布都被建模为具有可训练均值函数和固定方差的高斯分布，那么式7中的目标函数可简化为

$$L_\gamma(\epsilon_\theta) := \sum_{t=1}^T \gamma_t \mathbb{E}_{\mathbf{x}_0 \sim q(\mathbf{x}_0), \epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\left\| \epsilon_\theta^{(t)} (\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \epsilon_t) - \epsilon_t \right\|_2^2 \right] \quad (9)$$

- 其中， $\epsilon_\theta := \{\epsilon_\theta^{(t)}\}_{t=1}^T$ 是一组包含 T 个函数的集合，每个 $\epsilon_\theta^{(t)}: \mathcal{X} \rightarrow \mathcal{X}$ (由 t 索引) 是一个带有可训练参数 $\theta^{(t)}$ 的函数；
- $\gamma := [\gamma_1, \dots, \gamma_T]$ 是目标函数中依赖于 $\alpha_{1:T}$ 的正系数向量。

因此，只要西保江（1）的形不变，就可以使用训练好的

Non-Markovian 前向扩散过程

考虑一个由实向量 $\sigma \in \mathbb{R}_{>0}^T$ 索引的推断分布族 $\mathcal{Q}$ (是超参数), 可以定义:

$$\begin{cases} q_{\sigma}(\mathbf{x}_{1:T}|\mathbf{x}_0) := q_{\sigma}(\mathbf{x}_T|\mathbf{x}_0) \prod_{t=2}^T q_{\sigma}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \\ q_{\sigma}(\mathbf{x}_T|\mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_T}\mathbf{x}_0, (1 - \alpha_T)\mathbf{I}) \\ q_{\sigma}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}\left(\sqrt{\alpha_{t-1}}\mathbf{x}_0 + \sqrt{1 - \alpha_{t-1} - \sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\alpha_t}\mathbf{x}_0}{\sqrt{1 - \alpha_t}}, \sigma_t^2\mathbf{I}\right), \quad \forall t > 1 \end{cases} \quad (10)$$

上面的定义是可以确保下式成立的

$$q_{\sigma}(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_t}\mathbf{x}_0, (1 - \alpha_t)\mathbf{I}), \forall t \quad (11)$$

此结论证明过程会用到以下结论:

给定 $\mathbf{x}$ 的边缘高斯分布, 以及给定 $\mathbf{x}$ 时 $\mathbf{y}$ 的条件高斯分布, 形式如下:

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1}), \quad p(\mathbf{y} \mid \mathbf{x}) = \mathcal{N}(\mathbf{y} \mid \mathbf{A}\mathbf{x} + \mathbf{b}, \mathbf{L}^{-1})$$

y 的边缘分布以及给定 y 时 x 的条件分布由以下式子给出:

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y} \mid \mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{L}^{-1} + \mathbf{A}\boldsymbol{\Lambda}^{-1}\mathbf{A}^{\text{T}}), \quad p(\mathbf{x} \mid \mathbf{y}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\Sigma}\{\mathbf{A}^{\text{T}}\mathbf{L}(\mathbf{y} - \mathbf{b}) + \boldsymbol{\Lambda}\boldsymbol{\mu}\}, (\boldsymbol{\Lambda} + \mathbf{A}^{\text{T}}\mathbf{L}\mathbf{A})^{-1})$$

$q_\sigma(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_t}\mathbf{x}_0, (1 - \alpha_t)\mathbf{I})$ 的证明

使用数学归纳法。当 $t = T$ 时，命题成立。下面从 t 时刻向 $t - 1$ 时刻证明：
假设对于任意 $t \leq T$ ，若 $q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_{t-1}}\mathbf{x}_0, (1 - \alpha_{t-1})\mathbf{I})$ 成立，由 Bayes，我们有：

$$q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_0) := \int_{\mathbf{x}_t} q_\sigma(\mathbf{x}_t|\mathbf{x}_0) q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) d\mathbf{x}_t$$

并且

$$q_\sigma(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_t}\mathbf{x}_0, (1 - \alpha_t)\mathbf{I})$$

$$q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}\left(\sqrt{\alpha_{t-1}}\mathbf{x}_0 + \sqrt{1 - \alpha_{t-1} - \sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\alpha_t}\mathbf{x}_0}{\sqrt{1 - \alpha_t}}, \sigma_t^2\mathbf{I}\right)$$

于是 $q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_0)$ 是高斯分布，记为 $\mathcal{N}(\mu_{t-1}, \Sigma_{t-1})$ ，其中：

$$\mu_{t-1} = \sqrt{\alpha_{t-1}}\mathbf{x}_0 + \sqrt{1 - \alpha_{t-1} - \sigma_t^2} \cdot \frac{\sqrt{\alpha_t}\mathbf{x}_0 - \sqrt{\alpha_t}\mathbf{x}_0}{\sqrt{1 - \alpha_t}} = \sqrt{\alpha_{t-1}}\mathbf{x}_0$$

$$\Sigma_{t-1} = \sigma_t^2\mathbf{I} + \frac{1 - \alpha_{t-1} - \sigma_t^2}{1 - \alpha_t}(1 - \alpha_t)\mathbf{I} = (1 - \alpha_{t-1})\mathbf{I}$$

因此，原命题对 $t - 1$ 时刻亦成立，由数学归纳法的原理，原命题成立。

Non-Markovian 前向扩散过程的后验分布

直观上, 给定含噪观测 $\mathbf{x}_t$ 对应的生成过程 $p_\theta(\mathbf{x}_{0:T})$, 我们可以首先对相应的 $\mathbf{x}_0$ 进行预测, 然后通过反向条件分布 $q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 利用该预测来获得样本 $\mathbf{x}_{t-1}$ 。

对于 $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 和 $\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 可利用式8得到 $\mathbf{x}_t$ 。模型 $\epsilon_\theta^{(t)}(\mathbf{x}_t)$ 会在不知晓 $\mathbf{x}_0$ 的情况下从 $\mathbf{x}_t$ 预测 ϵ_t 。通过重写式8, 进而能够预测去噪观测值(denoised observation), 也就是给定 $\mathbf{x}_t$ 时对 $\mathbf{x}_0$ 的预测:

$$f_\theta^{(t)}(\mathbf{x}_t) := (\mathbf{x}_t - \sqrt{1 - \alpha_t} \cdot \epsilon_\theta^{(t)}(\mathbf{x}_t)) / \sqrt{\alpha_t} \quad (12)$$

然后, 我们用固定先验 $p_\theta(\mathbf{x}_T) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 定义生成过程:

$$p_\theta^{(t)}(\mathbf{x}_{t-1}|\mathbf{x}_t) = \begin{cases} \mathcal{N}(f_\theta^{(1)}(\mathbf{x}_t), \sigma_1^2 \mathbf{I}) & \text{if } t = 1 \\ q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, f_\theta^{(t)}(\mathbf{x}_t)) & \text{otherwise} \end{cases} \quad (13)$$

其中, $q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, f_\theta^{(t)}(\mathbf{x}_t))$ 是将式10中的 $\mathbf{x}_0$ 替换为 $f_\theta^{(t)}(\mathbf{x}_t)$ 后得到的, 即

$$q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, f_\theta^{(t)}(\mathbf{x}_t)) = \mathcal{N}\left(\sqrt{\alpha_{t-1}} f_\theta^{(t)}(\mathbf{x}_t) + \sqrt{1 - \alpha_{t-1} - \sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\alpha_t} f_\theta^{(t)}(\mathbf{x}_t)}{\sqrt{1 - \alpha_t}}, \sigma_t^2 \mathbf{I}\right)$$

定理: 对于所有 $\sigma > 0$ 存在 $\alpha \in \mathbb{R}^T$ 和 $C \in \mathbb{R}$ 使得 $I = I_\sigma + C$

(改)

(1) 从这一非良态开始, 计算 ρ_{eff} 。这由在上一节中出现的非良态 (DDDM) 上作

◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ 🔍

非 Markov 扩散逆过程的采样

根据式13中的 $p_\theta(\mathbf{x}_{1:T})$, 可通过以下方式从样本 $\mathbf{x}_t$ 生成样本 $\mathbf{x}_{t-1}$:

$$\mathbf{x}_{t-1} = \underbrace{\sqrt{\alpha_{t-1}} \left(\frac{\mathbf{x}_t - \sqrt{1 - \alpha_t} \epsilon_\theta^{(t)}(\mathbf{x}_t)}{\sqrt{\alpha_t}} \right)}_{\text{"predicted } \mathbf{x}_0"} + \underbrace{\sqrt{1 - \alpha_{t-1} - \sigma_t^2} \cdot \epsilon_\theta^{(t)}(\mathbf{x}_t)}_{\text{"direction pointing to } \mathbf{x}_t"} + \underbrace{\sigma_t \epsilon_t}_{\text{random noise}}$$

其中, $\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是与 $\mathbf{x}_t$ 独立的标准高斯噪声, 且我们定义 $\alpha_0 := 1$ 。对 σ 取值的不同选择会产生不同的生成过程, 同时都使用相同的模型 ϵ_θ , 因此无需重新训练模型。

- 对所有 t 有 $\sigma_t = \sqrt{\frac{1 - \alpha_{t-1}}{1 - \alpha_t}} \sqrt{1 - \frac{\alpha_t}{\alpha_{t-1}}}$ 时, 前向过程变为 Markov 过程, 生成过程则变为 DDPM 模型。
- 对所有 t 有 $\sigma_t = 0$: 此时, 除 $t = 1$ 外, 给定 $\mathbf{x}_{t-1}$ 和 $\mathbf{x}_0$ 时前向过程变为确定性的; 在生成过程中, 随机噪声 ϵ_t 前的系数变为零。

由此产生的模型成为隐式概率模型, 其中样本通过固定流程从隐变量生成 (从 $\mathbf{x}_T$ 到 $\mathbf{x}_0$)。因为它是由 DDPM 的目标函数训练得来的, 我们称上述模型为去噪扩散隐式模型(DDIM)。

利用 L_{simple} 实现加速采样

生成过程是对反向过程的近似。由于前向过程有 T 步，生成过程也被迫进行 T 步采样。然而，由于去噪目标 L_1 只要 $q_\sigma(\mathbf{x}_t|\mathbf{x}_0)$ 固定，就不依赖于特定的前向过程，我们也可以考虑长度小于 T 的前向过程，这能在无需训练不同模型的情况下加速相应的生成过程。




Figure 2: Graphical model for accelerated generation, where $\tau = [1, 3]$.

图 4: DDIM 加速采样的示意图

考虑定义在子集 $\{\mathbf{x}_{\tau_1}, \dots, \mathbf{x}_{\tau_S}\}$ 上的前向过程，其中 τ 是 $[1, \dots, T]$ 的一个长度为 S 的递增子序列。具体而言，我们在 $\mathbf{x}_{\tau_1}, \dots, \mathbf{x}_{\tau_S}$ 上定义顺序前向过程，使得 $q(\mathbf{x}_{\tau_i}|\mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_{\tau_i}}\mathbf{x}_0, (1 - \alpha_{\tau_i})\mathbf{I})$ 与“边缘分布”匹配，生成过程就可以在 τ 序列上去进行。

© 2006 The Authors
Journal compilation © 2006 Blackwell Publishing Ltd

(改)

(改)

我们将说明，只需对式 (12) 中的更新稍作修改，就能得到新的、更快的生成过程，这适用于去噪扩散概率模型 (DDPM)、去噪扩散隐式模型 (DDIM)，以及式 (10) 中考虑的所有生成过程。我们在附录 C.1 中详细介绍这些内容。原则上，这意味着我们可以用任意数量的前向步训练一个模型，但在生成过程中仅从其中一些步进行采样。因此，经训练的模型可考虑比 (Ho 等人, 2020) 中更多的步数，甚至可考虑连续时间变量 t (Chen 等人, 2020)。我们将这一方面的实证研究留作未来工作。

- 当 $\eta = 1$ 时，这涵盖了原始 DDPM 生成过程；
- 当 $\eta = 0$ 时，涵盖了 DDIM。

我们还考虑随机噪声标准差大于 $\sigma(1)$ 的 DDPM，记为 $\hat{\sigma}$ ： $\hat{\sigma}_{\tau_i} = \sqrt{1 - \frac{\alpha_{\tau_i}}{\alpha_{\tau_{i-1}}}}$ 。Ho 等人（2020 年）的实现中仅使用这种形式来生成 CIFAR-10 数据集的样本。

- 我们还考虑随机噪声标准差大于 $\sigma(1)$ 的 DDPM, 记

Ho 等人 (2020 年) 的实现中仅使用这种形式来生成 CIFAR-10 数据集的样本。

1111

相关应用

③ Score-Based Model

1111

1 Diffusion Model

2 Flow Matching

Flow-based Model

Neural ODEs & CNF

模型简述

数学原理

代码复现

相关应用

3 Score-Based Model

Flow-based Model




图 5: Flow-based Model 流程示意图⁴

模型框架:

- 数据集: 独立同分布样本 $\{x^1, x^2, \dots, x^m\} \sim p_{data}(x)$
- 任务: 学习分布 $p_G(x) \approx p_{data}(x)$
- 模型: 生成器 G
- 目标函数: $G^* = \arg \max_G \sum_{i=1}^m \log p_G(x^i) \approx \arg \min_G \text{KL}(p_{data} \parallel p_G)$

⁴ 本小节配图大多来自于 李宏毅 Flow-based model 2019.

数学原理

沿用上页记号, 由 $z^i \sim \pi(z)$, $x^i \sim p_G(x)$, $z^i = G^{-1}(x^i)$, 结合变量替换公式

$$p_G(x^i) = \pi(z^i) |\det(J_{G^{-1}})|$$

目标函数可转化为

$$G^* = \arg \max_G \sum_{i=1}^m \log \left(\pi(z^i) |\det(J_{G^{-1}})| \right) = \sum_{i=1}^m \log \pi \left(G^{-1}(x^i) \right) + \log |\det(J_{G^{-1}})|$$

困难:

- 如何计算 J_G , 如何求逆? (求任意一个 d 维数 Jacobian 之逆, 计算复杂度为 $O(d^3)$)
- 如何确保 G 是双射 (这也表明 x 与 z 维数相同), 如何计算 G^{-1} ?

以上问题表明, 我们需要对 G 进行限制: 一方面, G 要是双射 (微分同胚); 另一方面, G 的形式必须不能太复杂。想要效果好, 考虑进行叠加。

数学原理



图 6: 多层流变换示意图

经过 K 层变换,

$$x \xrightarrow{f_1} z_1 \xrightarrow{f_2} z_2 \xrightarrow{\cdots} z_{K-1} \xrightarrow{f_K} z_K = z$$

求其概率密度

$$p_1(x^i) = \pi(z^i) \left(\left| \det \left(J_{G_1^{-1}} \right) \right| \right)$$

$$p_2(x^i) = \pi(z^i) \left(\left| \det \left(J_{G_1^{-1}} \right) \right| \right) \left(\left| \det \left(J_{G_2^{-1}} \right) \right| \right)$$

...

$$p_K(x^i) = \pi(z^i) \left(\left| \det \left(J_{G_1^{-1}} \right) \right| \right) \cdots \left(\left| \det \left(J_{G_K^{-1}} \right) \right| \right)$$

$$\log p_K(x^i) = \log \pi(z^i) + \sum_{h=1}^K \log \left| \det \left(J_{G_h^{-1}} \right) \right|$$

数学原理

我们训练 G^{-1} ，再用 G 做生成。





图 7: 最大化对数似然的示意图

- 第一项会倾向于将 z^i 变为 0 向量（因为 $\max \log(\pi(z^i))$, $z^i \sim N(0, I)$ ）
- 第二项对第一项接近 0 的行为进行惩罚

耦合层的设计

图 8: 耦合层 (coupling layer)⁵⁶示意图

- F, H 可为任意函数, 无需可逆; $\beta_j = F_j(z_1, \dots, z_d)$, $\gamma_j = H_j(z_1, \dots, z_d)$
- $\mathbf{z}$ 的前 d 维直接复制为 $\mathbf{x}$; 后 $D - d$ 维则需进行变换。

$$\begin{cases} x_i = z_i, & i \leq d \\ x_i = \beta_i z_i + \gamma_i, & i > d \end{cases} \Rightarrow \begin{cases} z_i = x_i, & i \leq d \\ z_i = \frac{x_i - \gamma_i}{\beta_i}, & i > d \end{cases}$$

⁵ Dinh, L., Krueger, D., & Bengio, Y. "NICE: Non-linear Independent Components Estimation." ICLR 2015, <https://arxiv.org/abs/1410.8516>.

⁶ Dinh, L., Sohl-Dickstein, J., & Bengio, S. "Density estimation using Real NVP." ICLR 2017, <https://arxiv.org/abs/1605.08803>.

Jacobian 矩阵的计算




图 9: Jacobian 矩阵的计算

由于 $x_i = \beta_i z_i + \gamma_i$ ($i > d$),

$$\det(J_G) = \frac{\partial x_{d+1}}{\partial z_{d+1}} \frac{\partial x_{d+2}}{\partial z_{d+2}} \cdots \frac{\partial x_D}{\partial z_D} = \beta_{d+1} \beta_{d+2} \cdots \beta_D$$

为了使效果更好，对耦合层进行堆叠

- 如果只是直接堆叠 (左图), 这会导致生成数据中总有一片固定的部分。这是因为其来自初始的高斯分布的前 d 维分量始终不变。
- 为了解决左图问题, 我们可以通过将复制模块 (copy) 与仿射模块 (affine) 交换顺序的方式去解决左图的问题 (右图)。

NeurIPS 2018. <https://arxiv.org/abs/1807.03039>.

因为 $x = f(z) = Wz$,

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \\ w_{31} & w_{32} & w_{33} \end{bmatrix} \begin{bmatrix} z_1 \\ z_2 \\ z_3 \end{bmatrix} \Rightarrow J_f = \begin{bmatrix} \frac{\partial x_1}{\partial z_1} & \frac{\partial x_1}{\partial z_2} & \frac{\partial x_1}{\partial z_3} \\ \frac{\partial x_2}{\partial z_1} & \frac{\partial x_2}{\partial z_2} & \frac{\partial x_2}{\partial z_3} \\ \frac{\partial x_3}{\partial z_1} & \frac{\partial x_3}{\partial z_2} & \frac{\partial x_3}{\partial z_3} \end{bmatrix} = \begin{bmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \\ w_{31} & w_{32} & w_{33} \end{bmatrix} = W$$




图 12: Glow 中 Jacobian 矩阵示意图

- 绿色是输入，蓝色是输出，二者成对出现，每个都是 W ；
- W 是 3×3 的矩阵，行列式容易计算。最后再将行列式连乘即可。

应用：如何让人笑起来




图 13: Flow-based Model 人脸变形示意图


训练过程

- ① 收集不笑脸数据集、笑脸数据集；
- ② 分别计算不笑脸数据集、笑脸数据集中图片的 z 值，再分别计算两个数据集的均值 z_1, z_2 ，可得

$$z_{smile} = z_2 - z_1$$

生成过程

- ① 拿到待处理图片 x ，经过 G^{-1} ，得到 $z = G^{-1}(x)$ ；
- ② 计算 $z' = z + z_{smile}$
- ③ 生成 $x' = G(z')$



- **GAN:** 利用判别器 (Discriminator) 和生成器 (Generator) 进行对抗训练
- **VAE:** 最大化变分下界, 利用编码器 (Encoder) 和解码器 (Decoder) 学习数据的潜在分布
- **Flow-based Models:** 通过可逆分布变换 (Invertible transform of distributions) 直接建模数据分布
- **Diffusion Models:** 先逐步加噪, 再反向去噪

1 Diffusion Model

2 Flow Matching

Flow-based Model

Neural ODEs & CNF

Neural ODEs

Continuous Normalizing Flows

对比试验

模型简述

数学原理

代码复现

相关应用

3 Score-Based Model

ODEs 回顾

未知函数是一元函数的微分方程称为是常微分方程(ordinary differential equation, ODE), 简单的一阶 ODE 具有以下形式,

$$y'(t) = f(t, y), \quad y(t_0) = y_0$$

其中, y 是以 t 为自变量的函数, y_0 是初值, $y'(t)$ 是其关于 t 的导数。

当 $f(x, y)$ 为某些特定形式的时候, 我们可以得到 $y(t)$ 的解析解。但在一般应用场景, $f(t, y)$ 往往比较复杂, 导致无法求出解析解。我们只能被迫去求数值解。


在给定初值时, 任意一点 t 处的 $y(t)$ 取值可以由积分得到:

$$y(t) = y(t_0) + \int_{t_0}^t y'(t) dt = y_0 + \int_{t_0}^t f(t, y) dt$$

从上式中可以提炼出求解 ODE 数值解的 Euler 法。

$$y_{n+1} = y(t_n) + hy'(t_n) = y(t_n) + hf(t, y(t_n))$$

ResNet : $h_{t+1} = h_t + f(\theta_t, h_t)$



⁸He, K., Zhang, X., Ren, S., & Sun, J. "Deep Residual learning for Image Recognition " CVPR 2016

104111

Chen 等人⁹建立起一种 Neural ODEs 模型, 有效解决了以上问题。




图 16: 与 ResNet 的对比示意图

在训练方面，Chen 等人使用了一种**伴随灵敏度方法**，有效解决了 ODE 求解器进行可扩展的反向传播的内存开销问题。这使得在更大的模型中对常微分方程进行端到端训练成为可能。

⁹R. T. Q. Chen, Y. Rubanova, J. Bettencourt, and D. K. Duvenaud, "Neural Ordinary Differential Equations." NeurIPS 2018. <https://arxiv.org/abs/1806.07366>.

- **内存效率**：无需通过求解器的操作进行反向传播，不存储前向传播的任何中间量，使我们能够以恒定的内存成本（作为深度的函数）训练模型。
- **自适应计算**：可以评估模型的成本，能够随问题复杂度进行调整。对于实时或低功耗应用，可降低精度要求。
- **参数效率**：当隐藏单元的动态被参数化为时间的连续函数时，相邻“层”的参数会自动关联在一起，这会减少监督学习任务所需的参数数量。
- **可扩展且可逆的归一化流**：连续变换使得变量替换公式变得更易于计算。连续归一化流模型可避免归一化流的单单元瓶颈，且能通过最大似然直接进行训练。
- **连续时间序列模型**：RNN 需要对观测和发射间隔进行离散化，而连续定义的动力系统可自然纳入在任意时间到达的数据。

反向传播

训练连续深度网络的主要技术难点在于通过 ODE 求解器执行反向传播。对前向传播的操作很直接，但会产生高额内存成本并引入额外的数值误差。我们将 ODE 求解器视为黑箱，使用[伴随灵敏度方法](#)(Adjoint Sensitivity Method)(Pontryagin et al., 1962) 计算梯度。这种方法通过反向求解第二个经扩充的 ODE 来计算梯度，适用于所有 ODE 求解器。该方法随问题规模线性扩展，内存成本低，并且能显式控制数值误差。

考虑优化一个标量值损失函数 L ，其输入是 ODE 求解器的结果：

$$L(\mathbf{z}(t_1)) = L\left(\mathbf{z}(t_0) + \int_{t_0}^{t_1} f(\mathbf{z}(t), t, \theta) dt\right) = L(\text{ODESolve}(\mathbf{z}(t_0), f, t_0, t_1, \theta))$$

为了优化 L ，我们需要关于 θ 的梯度。

第一步是确定损失的梯度如何依赖于每个时刻的隐藏状态 $\mathbf{z}(t)$ 。下面式的 $\mathbf{a}(t)$ 被称为[伴随状态](#)(adjoint state)

$$\mathbf{a}(t) = \frac{\partial L}{\partial \mathbf{z}(t)}$$

其变化过程由另一个 ODE 给出，可视作是链式法则的连续版本，

$$\frac{d\mathbf{a}(t)}{dt} = -\mathbf{a}(t)^\top \frac{\partial f(\mathbf{z}(t), t, \theta)}{\partial \mathbf{z}} \quad (14)$$

反向传播




图 17: 伴随灵敏度方法示意图

再次调用 ODE 求解器计算 $\partial L / \partial \mathbf{z}(t_0)$ 。从其最终值 $\mathbf{z}(t_1)$ 开始，随伴随一起及时反向重新计算 $\mathbf{z}(t)$ 。

$$\frac{dL}{d\theta} = - \int_{t_1}^{t_0} \mathbf{a}(t)^\top \frac{\partial f(\mathbf{z}(t), t, \theta)}{\partial \theta} dt \quad (15)$$

式14的推导

(为方便表示, 本页默认使用行向量)

对于连续的隐藏状态, 我们可以将时间变化 ε 时刻后的变换写为:

$$\mathbf{z}(t + \varepsilon) = \int_t^{t+\varepsilon} f(\mathbf{z}(t), t, \theta) dt + \mathbf{z}(t) = T_\varepsilon(\mathbf{z}(t), t)$$

并且也可应用链式法则:

$$\frac{dL}{d\mathbf{z}(t)} = \frac{dL}{d\mathbf{z}(t + \varepsilon)} \frac{d\mathbf{z}(t + \varepsilon)}{d\mathbf{z}(t)} \Rightarrow \mathbf{a}(t) = \mathbf{a}(t + \varepsilon) \frac{\partial T_\varepsilon(\mathbf{z}(t), t)}{\partial \mathbf{z}(t)}$$

式14的证明可由导数的定义得出:

$$\begin{aligned} \frac{da(t)}{dt} &= \lim_{\varepsilon \rightarrow 0^+} \frac{\mathbf{a}(t + \varepsilon) - \mathbf{a}(t)}{\varepsilon} = \lim_{\varepsilon \rightarrow 0^+} \frac{\mathbf{a}(t + \varepsilon) - \mathbf{a}(t + \varepsilon) \frac{\partial}{\partial \mathbf{z}(t)} T_\varepsilon(\mathbf{z}(t))}{\varepsilon} \quad (\text{由上面的链式法则}) \\ &= \lim_{\varepsilon \rightarrow 0^+} \frac{\mathbf{a}(t + \varepsilon) - \mathbf{a}(t + \varepsilon) \frac{\partial}{\partial \mathbf{z}(t)} \left(\mathbf{z}(t) + \varepsilon f(\mathbf{z}(t), t, \theta) + \mathcal{O}(\varepsilon^2) \right)}{\varepsilon} \quad (\text{在 } \mathbf{z}(t) \text{ 附近进行 Taylor 展开}) \\ &= \lim_{\varepsilon \rightarrow 0^+} \frac{\mathbf{a}(t + \varepsilon) - \mathbf{a}(t + \varepsilon) \left(I + \varepsilon \frac{\partial f(\mathbf{z}(t), t, \theta)}{\partial \mathbf{z}(t)} + \mathcal{O}(\varepsilon^2) \right)}{\varepsilon} \\ &= \lim_{\varepsilon \rightarrow 0^+} \frac{-\varepsilon \mathbf{a}(t + \varepsilon) \frac{\partial f(\mathbf{z}(t), t, \theta)}{\partial \mathbf{z}(t)} + \mathcal{O}(\varepsilon^2)}{\varepsilon} = \lim_{\varepsilon \rightarrow 0^+} -\mathbf{a}(t + \varepsilon) \frac{\partial f(\mathbf{z}(t), t, \theta)}{\partial \mathbf{z}(t)} + \mathcal{O}(\varepsilon) \\ &= -\mathbf{a}(t) \frac{\partial f(\mathbf{z}(t), t, \theta)}{\partial \mathbf{z}(t)} \end{aligned}$$

式15的推导

我们对14进行推广可得关于 θ (相对于时间 t 而言为常数) 的梯度。即假设参数共享, θ 关于 t 不变, 有

$$\frac{\partial \theta(t)}{\partial t} = \mathbf{0}, \quad \frac{dt(t)}{dt} = 1$$

对将二者与 $\mathbf{z}$ 结合形成增广状态 (augmented state), 可得对应微分方程与伴随状态

$$\frac{d}{dt} \begin{bmatrix} \mathbf{z} \\ \theta \\ t \end{bmatrix} (t) = f_{\text{aug}}([\mathbf{z}, \theta, t]) := \begin{bmatrix} f([\mathbf{z}, \theta, t]) \\ \mathbf{0} \\ 1 \end{bmatrix}, \quad \mathbf{a}_{\text{aug}} := \begin{bmatrix} \mathbf{a} \\ \mathbf{a}_{\theta} \\ \mathbf{a}_t \end{bmatrix}, \quad \mathbf{a}_{\theta}(t) := \frac{dL}{d\theta(t)}, \quad \mathbf{a}_t(t) := \frac{dL}{dt(t)}$$

计算得 Jacobian 矩阵,

$$\frac{\partial f_{\text{aug}}}{\partial [\mathbf{z}, \theta, t]} = \begin{bmatrix} \frac{\partial f_{\text{aug}}^1}{\partial \mathbf{z}} & \frac{\partial f_{\text{aug}}^1}{\partial \theta} & \frac{\partial f_{\text{aug}}^1}{\partial t} \\ \frac{\partial f_{\text{aug}}^2}{\partial \mathbf{z}} & \frac{\partial f_{\text{aug}}^2}{\partial \theta} & \frac{\partial f_{\text{aug}}^2}{\partial t} \\ \frac{\partial f_{\text{aug}}^3}{\partial \mathbf{z}} & \frac{\partial f_{\text{aug}}^3}{\partial \theta} & \frac{\partial f_{\text{aug}}^3}{\partial t} \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial \mathbf{z}} & \frac{\partial f}{\partial \theta} & \frac{\partial f}{\partial t} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} \end{bmatrix} (t)$$

其中, 每个 $\mathbf{0}$ 是具有适当维度的零矩阵。

式15的推导

应用式14可得,

$$\frac{d\mathbf{a}_{aug}(t)}{dt} = - [\mathbf{a}(t) \quad \mathbf{a}_\theta(t) \quad \mathbf{a}_t(t)] \frac{\partial f_{aug}}{\partial [\mathbf{z}, \theta, t]}(t) = - \left[\mathbf{a} \frac{\partial f}{\partial \mathbf{z}} \quad \mathbf{a} \frac{\partial f}{\partial \theta} \quad \mathbf{a} \frac{\partial f}{\partial t} \right] (t)$$

于是,

$$\mathbf{a}_\theta(t) = \mathbf{a}(t) \frac{\partial f}{\partial \theta}, \quad \mathbf{a}_t(t) = -\mathbf{a}(t) \frac{\partial f}{\partial t}$$

令 $\mathbf{a}_\theta(t_N) = \mathbf{0}$ 可求得 L 关于参数 θ 的总梯度:

$$\frac{dL}{d\theta} = \mathbf{a}_\theta(t_0) = \mathbf{a}_\theta(t_N) - \int_{t_N}^{t_0} \mathbf{a}(t) \frac{\partial f(\mathbf{z}(t), t, \theta)}{\partial \theta} dt = - \int_{t_N}^{t_0} \mathbf{a}(t) \frac{\partial f(\mathbf{z}(t), t, \theta)}{\partial \theta} dt$$

类似可得

$$\begin{aligned} \frac{dL}{dt_N} &= \frac{dL}{d\mathbf{z}(t)} \frac{d\mathbf{z}(t)}{dt} \Big|_{t=t_N} = \mathbf{a}(t_N) f(\mathbf{z}(t_N), t_N, \theta) \\ \frac{dL}{dt_0} &= \mathbf{a}_t(t_0) = \mathbf{a}_t(t_N) - \int_{t_N}^{t_0} \mathbf{a}(t) \frac{\partial f(\mathbf{z}(t), t, \theta)}{\partial t} dt \end{aligned}$$

具体算法

Algorithm 2 Complete reverse-mode derivative of an ODE initial value problem

Input: dynamics parameters θ , start time t_0 , stop time t_1 , final state $\mathbf{z}(t_1)$, loss gradient $\partial L / \partial \mathbf{z}(t_1)$

$\frac{\partial L}{\partial t_1} = \frac{\partial L}{\partial \mathbf{z}(t_1)}^\top f(\mathbf{z}(t_1), t_1, \theta)$ ▷ Compute gradient w.r.t. t_1

$s_0 = [\mathbf{z}(t_1), \frac{\partial L}{\partial \mathbf{z}(t_1)}, \mathbf{0}_{|\theta|}, -\frac{\partial L}{\partial t_1}]$ ▷ Define initial augmented state

def aug_dynamics($[\mathbf{z}(t), \mathbf{a}(t), \cdot, \cdot], t, \theta$): ▷ Define dynamics on augmented state

return $[f(\mathbf{z}(t), t, \theta), -\mathbf{a}(t)^\top \frac{\partial f}{\partial \mathbf{z}}, -\mathbf{a}(t)^\top \frac{\partial f}{\partial \theta}, -\mathbf{a}(t)^\top \frac{\partial f}{\partial t}]$ ▷ Compute vector-Jacobian products

$[\mathbf{z}(t_0), \frac{\partial L}{\partial \mathbf{z}(t_0)}, \frac{\partial L}{\partial \theta}, \frac{\partial L}{\partial t_0}] = \text{ODESolve}(s_0, \text{aug_dynamics}, t_1, t_0, \theta)$ ▷ Solve reverse-time ODE

return $\frac{\partial L}{\partial \mathbf{z}(t_0)}, \frac{\partial L}{\partial \theta}, \frac{\partial L}{\partial t_0}, \frac{\partial L}{\partial t_1}$ ▷ Return all gradients

图 18: ODE 初值问题的反向传播算法

CNF 的数学原理

假设样本间通过双射 f 进行变换,

$$\mathbf{z}_1 = f(\mathbf{z}_0) \Rightarrow \log p(\mathbf{z}_1) = \log p(\mathbf{z}_0) - \log \left| \det \frac{\partial f}{\partial \mathbf{z}_0} \right| \Rightarrow \log p(\mathbf{z}_1) - \log p(\mathbf{z}_0) = -\log \left| \det \frac{\partial f}{\partial \mathbf{z}_0} \right|$$

将上式进行“连续化”。假设从时间 t 到 $t + \varepsilon$, $\mathbf{z}(t)$ 经变换得到 $\mathbf{z}(t + \varepsilon)$, 根据变量替换公式,

$$p(\mathbf{z}(t + \varepsilon)) = p(\mathbf{z}(t)) \cdot \left| \det \frac{\partial \mathbf{z}(t)}{\partial \mathbf{z}(t + \varepsilon)} \right| \Rightarrow \log p(\mathbf{z}(t + \varepsilon)) = \log p(\mathbf{z}(t)) + \log \left| \det \frac{\partial \mathbf{z}(t)}{\partial \mathbf{z}(t + \varepsilon)} \right|$$

记

$$\mathbf{z}(t + \varepsilon) = \mathbf{z}(t) + \epsilon f(\mathbf{z}(t), t, \theta) + \cdots = T_\varepsilon(\mathbf{z}(t))$$

于是有,

$$\log p(\mathbf{z}(t + \varepsilon)) = \log p(\mathbf{z}(t)) - \log \left| \det \frac{\partial \mathbf{z}(t + \varepsilon)}{\partial \mathbf{z}} \right| = \log p(\mathbf{z}(t)) - \log \left| \det \frac{\partial T_\varepsilon(\mathbf{z}(t))}{\partial \mathbf{z}} \right|$$

瞬时换元公式的证明

定理（瞬时换元公式）：设 $\mathbf{z}(t)$ 是有限连续随机变量，其概率密度 $p(\mathbf{z}(t))$ 依赖于时间。设 $\frac{d\mathbf{z}}{dt} = f(\mathbf{z}(t), t)$ 是描述 $\mathbf{z}(t)$ 连续时间变换的微分方程。假设 f 关于 $\mathbf{z}$ 是 Lipschitz 连续的，且关于 t 连续，那么对数概率的变化也遵循一个微分方程：

$$\frac{\partial \log p(\mathbf{z}(t))}{\partial t} = -\text{tr} \left(\frac{df}{d\mathbf{z}(t)} \right)$$

定理的说明：与上页的行列式不同，我们现在仅需进行迹运算。此外，微分方程 f 无需是双射的。因为如果满足唯一性条件，那么整个变换会自动成为双射。

证明：我们对 $\log p(\mathbf{z}(t))$ 随时间的有限变化取无穷小极限。

首先，我们将时间变化 ε 时 $\mathbf{z}$ 的变换表示为 $T_\varepsilon(\mathbf{z}(t))$

假设 f 关于 $\mathbf{z}(t)$ 是 Lipschitz 连续的，且关于 t 连续，因此根据 Picard 存在定理，每个初值问题都有唯一解；再假设 $\mathbf{z}(t)$ 是有界的。这些条件意味着 $f, T_\varepsilon, \frac{\partial}{\partial \mathbf{z}} T_\varepsilon$ 均有界。这些条件让我们得以来交换极限和乘积运算。

瞬时换元公式的证明

$$\begin{aligned}
 \frac{\partial \log p(\mathbf{z}(t))}{\partial t} &= \lim_{\varepsilon \rightarrow 0^+} \frac{\log p(\mathbf{z}(t)) - \log \left| \det \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right| - \log p(\mathbf{z}(t))}{\varepsilon} \\
 &= - \lim_{\varepsilon \rightarrow 0^+} \frac{\log \left| \det \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right|}{\varepsilon} = - \lim_{\varepsilon \rightarrow 0^+} \frac{\frac{\partial}{\partial \varepsilon} \log \left| \det \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right|}{\frac{\partial}{\partial \varepsilon} \varepsilon} \quad (\text{L'Hospital}) \\
 &= - \lim_{\varepsilon \rightarrow 0^+} \frac{\frac{\partial}{\partial \varepsilon} \left| \det \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right|}{\left| \det \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right|} \left[\frac{\partial \log(\mathbf{z})}{\partial \mathbf{z}} \Big|_{\mathbf{z}=\mathbf{1}} = 1 \right] \\
 &= - \underbrace{\left(\lim_{\varepsilon \rightarrow 0^+} \frac{\partial}{\partial \varepsilon} \left| \det \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right| \right)}_{\text{bounded}} \underbrace{\left(\lim_{\varepsilon \rightarrow 0^+} \frac{1}{\left| \det \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right|} \right)}_{=1} \\
 &= - \lim_{\varepsilon \rightarrow 0^+} \frac{\partial}{\partial \varepsilon} \left| \det \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right|
 \end{aligned}$$

瞬时换元公式的证明

由伴随矩阵 $(A^*, \text{adj}(A))$ 的性质,

$$A^{-1} = \frac{1}{|A|} (A^*)$$

可得

$$\frac{d|A|}{dt} = |A| \text{tr} \left(\frac{1}{|A|} A^* \frac{dA}{dt} \right)$$

利用上面公式可得,

$$\begin{aligned} \frac{\partial \log p(\mathbf{z}(t))}{\partial t} &= - \lim_{\varepsilon \rightarrow 0^+} \frac{\partial}{\partial \varepsilon} \left| \det \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right| \\ &= - \lim_{\varepsilon \rightarrow 0^+} \text{tr} \left(\text{adj} \left(\frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right) \frac{\partial}{\partial \varepsilon} \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right) \quad (\det \rightarrow 1, \varepsilon \rightarrow 0^+) \\ &= - \text{tr} \left(\underbrace{\left(\lim_{\varepsilon \rightarrow 0^+} \text{adj} \left(\frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right) \right)}_{=I} \left(\lim_{\varepsilon \rightarrow 0^+} \frac{\partial}{\partial \varepsilon} \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right) \right) \\ &= - \text{tr} \left(\lim_{\varepsilon \rightarrow 0^+} \frac{\partial}{\partial \varepsilon} \frac{\partial}{\partial \mathbf{z}} T_\varepsilon(\mathbf{z}(t)) \right) \end{aligned}$$

瞬时换元公式的证明

对 T_ε 进行 Taylor 展开,

$$\begin{aligned}
 \frac{\partial \log p(\mathbf{z}(t))}{\partial t} &= -\text{tr} \left(\lim_{\varepsilon \rightarrow 0^+} \frac{\partial}{\partial \varepsilon} \frac{\partial}{\partial \mathbf{z}} (\mathbf{z} + \varepsilon f(\mathbf{z}(t), t) + \mathcal{O}(\varepsilon^2) + \mathcal{O}(\varepsilon^3) + \dots) \right) \\
 &= -\text{tr} \left(\lim_{\varepsilon \rightarrow 0^+} \frac{\partial}{\partial \varepsilon} \left(I + \frac{\partial}{\partial \mathbf{z}} \varepsilon f(\mathbf{z}(t), t) + \mathcal{O}(\varepsilon^2) + \mathcal{O}(\varepsilon^3) + \dots \right) \right) \\
 &= -\text{tr} \left(\lim_{\varepsilon \rightarrow 0^+} \left(\frac{\partial}{\partial \mathbf{z}} f(\mathbf{z}(t), t) + \mathcal{O}(\varepsilon) + \mathcal{O}(\varepsilon^2) + \dots \right) \right) \\
 &= -\text{tr} \left(\frac{\partial}{\partial \mathbf{z}} f(\mathbf{z}(t), t) \right)
 \end{aligned}$$

□

2023 陈宝泉 西安交通大学

NF 与 CNF 的对比实验 1: 密度匹配





图 19: NF 的模型容量由其深度 (K) 决定, 而 CNF 通过增加宽度 (M) 即可提升容量, 这使它更易于训练

论文中 CNF 使用 Adam 优化器训练 10,000 次迭代。NF 使用 RMSprop 优化器训练 500,000 次迭代。对于这项任务，我们将 $\text{KL}(q(\mathbf{x})\|p(\mathbf{x}))$ 作为损失函数最小化，其中 q 是流模型，目标密度 $p(\cdot)$ 可求的。如上图，CNF 能实现更低的损失。



上图展示了 CNF 和 NF 学习的动态过程。经短时间变换后分布呈现初始平面流位置, CNF 为拟合双圆分布旋转平面流使粒子均匀成圆, 其变换平滑、可解释; 而 NF 变换反直觉, 难拟合双月数据集。

① Diffusion Model

② Flow Matching

Flow-based Model

Neural ODEs & CNF

模型简述

数学原理

代码复现

相关应用

③ Score-Based Model

模型简述

Flow Matching¹¹模型基于连续归一化流 (CNFs)，提出无模拟的训练框架，通过回归条件概率路径的向量场来监督 CNF 训练，突破扩散模型对简单概率路径的限制，支持任意概率路径（如最优传输路径），实现更高效的生成建模。

12

¹¹Lipman, Yaron, et al. "Flow Matching for Generative Modeling." ICLR 2023, <https://arxiv.org/abs/2210.02747>.

¹²Lipman, Yaron, et al. "Flow Matching Guide and Code." arXiv preprint arXiv:2412.06264, 2024. <https://arxiv.org/abs/2412.06264>.

10-11-2019

- **概率路径构造**：定义从标准正态分布到数据分布的连续变换路径，包含扩散路径（如方差爆炸 VE、方差保持 VP）和非扩散路径（如最优传输 OT 位移插值）；
- **向量场回归**：通过神经网络拟合目标向量场，利用条件流匹配 (CFM) 将难解的边缘向量场分解为可计算的条件向量场，避免显式求解复杂积分。

模型简述




图 21: Flow Matching 示意图

核心优势： Flow Matching 通过设计灵活的概率路径，在生成效率和样本质量上超越传统扩散模型：

与扩散模型（如 DDPM、DDIM）相比，Flow Matching 具有以下特性：

- 训练稳定性：基于向量场回归的损失函数更平滑，在 ImageNet 训练中收敛速度提升 50% 以上，FID 曲线下降更陡峭；
- 采样效率：OT 路径的直线轨迹避免扩散路径的“过冲”现象，固定步长求解器下用 60% 计算量即可达到和 DDIM 相当

① Diffusion Model

② Flow Matching

Flow-based Model

Neural ODEs & CNF

模型简述

数学原理

代码复现

相关应用

③ Score-Based Model

回顾: CNFs

设 $\mathbb{R}^d$ 为数据空间, 数据点 $x = (x^1, \dots, x^d) \in \mathbb{R}^d$ 。本文中使用的两个重要对象是: 概率密度路径 $p: [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}_{>0}$, 它是一个时变概率密度函数, 即 $\int p_t(x) dx = 1$; 以及时变向量场 $v: [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 。向量场 v_t 可用于构造一个时变微分同胚映射, 称为流(flow) $\phi: [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$, 通过 ODE 定义:

$$\begin{aligned}\frac{d}{dt}\phi_t(x) &= v_t(\phi_t(x)) \\ \phi_0(x) &= x\end{aligned}$$

此前, Chen 等人提出用神经网络对向量场 v_t 进行建模, 即 $v_t(x; \theta)$, 其中 $\theta \in \mathbb{R}^p$ 是其可学习参数, 这进而得到流 ϕ_t 的深度参数化模型, 称为 CNF。CNF 用于通过前推方程将简单的先验分布 p_0 (如纯噪声) 重塑为更复杂的分布 p_1 :

$$p_t = [\phi_t]_* p_0 \quad (16)$$

其中, 前推算子(push-forward operator) $*$ 定义为:

$$[\phi_t]_* p_0(x) = p_0(\phi_t^{-1}(x)) \det \left[\frac{\partial \phi_t^{-1}}{\partial x}(x) \right]$$

回顾

若向量场 v_t 的流 ϕ_t 满足方程16, 则称该向量场生成**概率密度路径**(probability density path) p_t 。

检验向量场 v_t 是否生成概率路径 p_t 的一种方法是利用连续性方程 (Villani, 2009)。它是一个偏微分方程 (PDE), 为确保向量场 v_t 生成 p_t 提供了充要条件:

$$\frac{d}{dt}p_t(x) + \operatorname{div}(p_t(x)v_t(x)) = 0 \quad (17)$$

其中, 散度算子 div 是相对于空间变量 $x = (x^1, \dots, x^d)$ 定义的, 即 $\operatorname{div} = \sum_{i=1}^d \frac{\partial}{\partial x^i}$ 。

数学原理

设 x_1 为根据某个未知数据分布 $q(x_1)$ 分布的随机变量。我们假设只能获取来自 $q(x_1)$ 的数据样本，但无法获取密度函数本身。此外，设 p_t 为一条概率路径，使得 $p_0 = p$ 是一个简单分布，比如标准正态分布 $p(x) = \mathcal{N}(x|0, I)$ ，且让 p_1 在分布上近似等于 q 。我们稍后会讨论如何构造这样一条路径。流匹配目标就是为了匹配这个目标概率路径而设计的，这将使我们能够从 p_0 流动到 p_1 。给定一个目标概率密度路径 $p_t(x)$ 以及生成 $p_t(x)$ 的相应向量场 $u_t(x)$ ，我们将流匹配 (FM) 目标定义为：

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t, p_t(x)} \|v_t(x) - u_t(x)\|^2 \quad (18)$$

其中， θ 表示 CNF 向量场 v_t 的可学习参数， $t \sim \mathcal{U}[0, 1]$ ，且 $x \sim p_t(x)$ 。简而言之，FM 损失用神经网络 v_t 对向量场 u_t 进行回归。当损失达到零时，学习到的 CNF 模型将生成 $p_t(x)$ 。

数学原理

流匹配是一个简单且有吸引力的目标，但就其本身而言，在实践中直接使用是不可行的，因为我们无法预先知晓合适的 p_t 和 u_t 是什么。有很多概率路径的选择可以满足 $p_1(x) \approx q(x)$ ，更重要的是，我们通常无法获取生成期望 p_t 的闭式 u_t 。

我们将展示可以使用仅按样本定义的概率路径和向量场来构造 p_t 和 u_t ，并且一种恰当的聚合方法可得到期望的 p_t 和 u_t 。此外，这种构造方法能让我们为流匹配创建一个更易于处理的目标。

定理 1: 条件概率路径与边缘概率路径

从条件概率路径和向量场构造 p_t 、 u_t 构造目标概率路径的一种简单方法是通过更简单的概率路径的混合：给定一个特定的数据样本 x_1 ，我们用 $p_t(x|x_1)$ 表示条件概率路径，使其在时间 $t = 0$ 时满足 $p_0(x|x_1) = p(x)$ ，并将 $t = 1$ 时的 $p_1(x|x_1)$ 设计为集中在 $x = x_1$ 附近的分布，比如 $p_1(x|x_1) = \mathcal{N}(x|x_1, \sigma^2 I)$ 。对条件概率路径关于 $q(x_1)$ 求边缘分布，得到边缘概率路径(marginal probability path)：

$$p_t(x) = \int p_t(x|x_1)q(x_1)dx_1 \quad (19)$$

特别地，在时间 $t = 1$ 时，边缘概率 p_1 是一种混合分布，能很好地近似数据分布 q ：

$$p_1(x) = \int p_1(x|x_1)q(x_1)dx_1 \approx q(x)$$

有趣的是，我们还可以通过对条件向量场进行“边缘化”来定义边缘向量场(假设对所有 t 和 x ， $p_t(x) > 0$)：

$$u_t(x) = \int u_t(x|x_1) \frac{p_t(x|x_1)q(x_1)}{p_t(x)} dx_1 \quad (20)$$

其中， $u_t(\cdot|x_1) : \mathbb{R}^d \rightarrow \mathbb{R}^d$ 是生成 $p_t(\cdot|x_1)$ 的条件向量场。这看起来可能不直观，但这种聚合条件向量场的方式，实际上能得到用于建模边缘概率路径的正确向量场。

定理 1: 条件概率路径与边缘概率路径

我们的第一个关键观察如下:

边缘向量场 (式20) 生成边缘概率路径 (式19)。

这在条件向量场 (生成条件概率路径的向量场) 和边缘向量场 (生成边缘概率路径的向量场) 之间建立了一种令人意外的联系。这种联系让我们能够将未知且难以处理的边缘向量场分解为更简单的条件向量场, 而条件向量场的定义要简单得多, 因为它们仅依赖于单个数据样本。我们在以下定理中对其进行形式化表述。

定理: 给定生成条件概率路径 $p_t(x|x_1)$ 的向量场 $u_t(x|x_1)$, 对于任意分布 $q(x_1)$, 式20中的边缘向量场 u_t 会生成式 6 中的边缘概率路径 p_t , 即 u_t 和 p_t 满足连续性方程 (式17)。

定理 1 的证明

证明：为验证这一点，我们检查 p_t 和 u_t 是否满足连续性方程（式17）：

$$\begin{aligned}
 \frac{d}{dt} p_t(x) &= \frac{d}{dt} \int (p_t(x|x_1)) q(x_1) dx_1 = \int \left(\frac{d}{dt} p_t(x|x_1) \right) q(x_1) dx_1 \\
 &= - \int \operatorname{div} (u_t(x|x_1) p_t(x|x_1)) q(x_1) dx_1 \\
 &= - \operatorname{div} \left(\int u_t(x|x_1) p_t(x|x_1) q(x_1) dx_1 \right) \\
 &= - \operatorname{div} (u_t(x) p_t(x)),
 \end{aligned}$$

□

结论：如果条件向量场按照一个条件概率路径行走，那么事实上页实现了在边缘向量场按照一个边缘概率路径的行走。

因此我们只需要去来求条件向量场的预测！

定理 2: 条件流匹配

遗憾的是, 由于边缘概率路径和向量场 (VF) 定义 (式19和式20) 中存在难以处理的积分, 计算 u_t 仍然不可行, 因此, 直接计算原始流匹配目标的无偏估计量也不可行。相反, 我们提出一个更简单的目标, 令人惊讶的是, 它会产生与原始目标相同的最优解。具体来说, 我们考虑**条件流匹配**(Conditional Flow Matching, CFM) 目标:

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, q(x_1), p_t(x|x_1)} \|v_t(x) - u_t(x|x_1)\|^2 \quad (21)$$

其中, $t \sim \mathcal{U}[0, 1]$, $x_1 \sim q(x_1)$, 且现在 $x \sim p_t(x|x_1)$ 。与 FM 目标不同, CFM 目标让我们能够轻松采样无偏估计, 只要我们可以从 $p_t(x|x_1)$ 中高效采样并计算 $u_t(x|x_1)$, 而由于它们是基于单个样本定义的, 这两项操作都很容易完成。因此, 我们的第二个关键观察是:

FM (17) 和 CFM (式21) 目标关于 θ 的梯度相同。

也就是说, 优化 CFM 目标 (在期望意义上) 等同于优化 FM 目标。因此, 这使我们能够训练一个 CNF 来生成边缘概率路径 p_t —特别是, 在 $t=1$ 时近似未知的数据分布 q —而无需访问边缘概率路径或边缘向量场。我们只需设计合适的条件概率路径和向量场即可。我们在以下定理中形式化这一性质。

定理 2: 假设对于所有 $x \in \mathbb{R}^d$ 和 $t \in [0, 1]$, 有 $p_t(x) > 0$, 那么, 除去一个与 θ 无关的常数, $\mathcal{L}_{\text{CFM}}$ 和 $\mathcal{L}_{\text{FM}}$ 相等。因此, $\nabla_{\theta} \mathcal{L}_{\text{FM}}(\theta) = \nabla_{\theta} \mathcal{L}_{\text{CFM}}(\theta)$ 。

定理 2 的证明

证明：为确保所有积分存在，并允许 (Fubini 定理) 交换积分顺序，在以下推导中，我们假设 $q(x)$ 和 $p_t(x|x_1)$ 随着 $\|x\| \rightarrow \infty$ 以足够快的速度衰减至零，且 u_t 、 v_t 、 $\nabla_\theta v_t$ 是有界的。

首先，利用 2-范数的标准双线性性质，我们有：

$$\begin{aligned}\|v_t(x) - u_t(x)\|^2 &= \|v_t(x)\|^2 - 2\langle v_t(x), u_t(x) \rangle + \|u_t(x)\|^2 \\ \|v_t(x) - u_t(x|x_1)\|^2 &= \|v_t(x)\|^2 - 2\langle v_t(x), u_t(x|x_1) \rangle + \|u_t(x|x_1)\|^2\end{aligned}$$

接下来，注意到 u_t 与 θ 无关，并注意到：

$$\begin{aligned}\mathbb{E}_{p_t(x)} \|v_t(x)\|^2 &= \int \|v_t(x)\|^2 p_t(x) dx \\ &= \int \int \|v_t(x)\|^2 p_t(x|x_1) q(x_1) dx_1 dx \\ &= \mathbb{E}_{q(x_1), p_t(x|x_1)} \|v_t(x)\|^2,\end{aligned}$$

其中，第二个等式利用了式 6，第三个等式交换了积分顺序。

定理 2 的证明

接下来,

$$\begin{aligned}
 \mathbb{E}_{p_t(x)} \langle v_t(x), u_t(x) \rangle &= \int \left\langle v_t(x), \frac{\int u_t(x|x_1) p_t(x|x_1) q(x_1) dx_1}{p_t(x)} \right\rangle p_t(x) dx \\
 &= \int \left\langle v_t(x), \int u_t(x|x_1) p_t(x|x_1) q(x_1) dx_1 \right\rangle dx \\
 &= \int \int \langle v_t(x), u_t(x|x_1) \rangle p_t(x|x_1) q(x_1) dx_1 dx \\
 &= \mathbb{E}_{q(x_1), p_t(x|x_1)} \langle v_t(x), u_t(x|x_1) \rangle,
 \end{aligned}$$

其中, 最后一个等式再次交换了积分顺序。 $\square$

结论: FM 和 CFM 梯度是处处相等的, 因此 loss 权重的值是一样的。

定理 3:

条件流匹配目标适用于任何条件概率路径和条件向量场的选择。在本节中，我们将讨论针对一类通用高斯条件概率路径，如何构造 $p_t(x|x_1)$ 和 $u_t(x|x_1)$ 。具体来说，我们考虑形式如下的条件概率路径：

$$p_t(x|x_1) = \mathcal{N}(x \mid \mu_t(x_1), \sigma_t(x_1)^2 I)$$

其中， $\mu : [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 是高斯分布的时变均值，而 $\sigma : [0, 1] \times \mathbb{R} \rightarrow \mathbb{R}_{>0}$ 描述时变标量标准差。我们设定 $\mu_0(x_1) = 0$ 且 $\sigma_0(x_1) = 1$ ，这样所有条件概率路径在 $t = 0$ 时都收敛到相同的标准高斯噪声分布 $p(x) = \mathcal{N}(x \mid 0, I)$ 。然后我们设定 $\mu_1(x_1) = x_1$ 且 $\sigma_1(x_1) = \sigma_{\min}$ ，其中 $\sigma_{\min}$ 被设定为足够小，使得 $p_1(x|x_1)$ 是一个以 x_1 为中心的集中高斯分布。

有无数个向量场可以生成任何特定的概率路径（例如，通过向连续性方程添加无散度分量，见方程 26），但主要的变化源于存在一些分量，这些分量使潜在分布保持不变——例如，当分布是旋转不变时，旋转分量会导致不必要的额外计算。我们决定使用与高斯分布的典型变换相对应的最简单向量场。具体来说，考虑（以 x_1 为条件的）流：

$$\psi_t(x) = \sigma_t(x_1)x + \mu_t(x_1)$$

定理 3

当 x 服从标准高斯分布时, $\psi_t(x)$ 是仿射变换, 映射到均值为 $\mu_t(x_1)$ 、标准差为 $\sigma_t(x_1)$ 的正态分布随机变量。也就是说, 根据方程 4, ψ_t 将噪声分布 $p_0(x|x_1) = p(x)$ 推送到 $p_t(x|x_1)$, 即:

$$[\psi_t]_* p(x) = p_t(x|x_1)$$

该流随后提供了一个生成条件概率路径的向量场:

$$\frac{d}{dt} \psi_t(x) = u_t(\psi_t(x)|x_1)$$

用仅含 x_0 的形式重新参数化 $p_t(x|x_1)$, 并将方程 13 代入 CFM 损失中, 我们得到:

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, q(x_1), p(x_0)} \left\| v_t(\psi_t(x_0)) - \frac{d}{dt} \psi_t(x_0) \right\|^2$$

由于 ψ_t 是简单的 (可逆的) 仿射映射, 我们可以使用方程 13 以闭式解出 u_t 。设 $f^\cdot$ 表示对时间的导数, 即, 对于时变函数 f , $f^\cdot = \frac{d}{dt} f$ 。

定理 3 的证明

定理 3: 设 $p_t(x|x_1)$ 为方程 10 中所示的高斯概率路径, ψ_t 为方程 11 中与其对应的流映射。那么, 定义 ψ_t 的唯一向量场具有如下形式:

$$u_t(x|x_1) = \frac{\sigma'_t(x_1)}{\sigma_t(x_1)}(x - \mu_t(x_1)) + \mu'_t(x_1)$$

因此, $u_t(x|x_1)$ 生成高斯路径 $p_t(x|x_1)$ 。

证明: 为简化符号, 令 $w_t(x) = u_t(x|x_1)$ 。现在考虑方程 1:

$$\frac{d}{dt}\psi_t(x) = w_t(\psi_t(x))$$

由于 ψ_t 是可逆的 (因为 $\sigma_t(x_1) > 0$), 我们令 $x = \psi^{-1}(y)$, 可得:

$$\psi'_t(\psi^{-1}(y)) = w_t(y)$$

这里我们用撇号表示导数, 以强调 ψ'_t 是在 $\psi^{-1}(y)$ 处求值。现在, 对 $\psi_t(x)$ 求逆可得:

$$\psi_t^{-1}(y) = \frac{y - \mu_t(x_1)}{\sigma_t(x_1)}$$

对 ψ_t 关于 t 求导:

$$\psi'_t(x) = \sigma'_t(x_1)x + \mu'_t(x_1)$$

将最后这两个方程代入方程 1, 我们得到

一些特殊情形

- Diffusion conditional VFs:

- ① 方差爆炸 (Variance Exploding) 路径:

$$p_t(x) = \mathcal{N}(x \mid x_1, \sigma_{1-t}^2 I), \sigma_0 = 0, \sigma_1 \gg 1$$

转变为 Score Matching

- ② 方差保持 (Variance Preserving) 路径:

$$p_t(x \mid x_1) = \mathcal{N}(x \mid \alpha_{1-t} x_1, (1 - \alpha_{1-t}^2) I)$$

转变为 DDPM

- Optimal Transport conditional VFs:

$$\mu_t(x) = tx_1, \text{ and } \sigma_t(x) = 1 - (1 - \sigma_{\min})t$$

对比实验





图 22: 与扩散路径的条件得分函数相比, 最优传输 (OT) 路径的条件向量场在时间上具有恒定方向, 用参数化模型拟合起来可能更简单。蓝色表示较大的幅值, 红色表示较小的幅值。

图 23: 扩散模型与最优传输的轨迹

根据定理 3, OT 路径由以下向量场生成:

$$u_t(x | x_1) = \frac{x_1 - (1 - \sigma_{\min})x}{1 - (1 - \sigma_{\min})t}$$

对应的条件流为

$$\psi_t(x) = (1 - (1 - \sigma_{\min})t)x + tx_1,$$

CFM 损失的形式为

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, q(x_1), p(x_0)} \|\mathbf{v}_t(\psi_t(x_0)) - (x_1 - (1 - \sigma_{\min})x_0)\|^2$$

让均值和标准差线性变化, 不仅能得到简单直观的路径, 实际上在以下意义上也是最优的。条件流 $\psi_t(x)$ 实际上是两个高斯分布 $p_0(x|x_1)$ 和 $p_1(x|x_1)$ 之间的 OT 位移映射。

① Diffusion Model

② Flow Matching

Flow-based Model

Neural ODEs & CNF

模型简述

数学原理

代码复现

相关应用

③ Score-Based Model

用 Beamer 很高大上？

1111

① Diffusion Model

② Flow Matching

Flow-based Model

Neural ODEs & CNF

模型简述

数学原理

代码复现

相关应用

③ Score-Based Model

用 Beamer 很高大上？

1111

① Diffusion Model

② Flow Matching

③ Score-Based Model

Energy-Based Model

模型简述

Score-based Generative Modeling 及其问题

NCSN

相关应用

① Diffusion Model

② Flow Matching

③ Score-Based Model

Energy-Based Model

模型简述

Score-based Generative Modeling 及其问题

NCSN

相关应用

① Diffusion Model

② Flow Matching

③ Score-Based Model

Energy-Based Model

模型简述

Score-based Generative Modeling 及其问题

NCSN

相关应用

模型简述

训练目标




图 24: Score-Based Model 训练目标¹³

模型框架¹⁴:

- 已知: 独立同分布样本 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\} \sim p_{\text{data}}(\mathbf{x})$
- 任务: 估计得分 $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$
- 模型: 一个可学习的向量值函数 $s_{\theta}(\mathbf{x}) : \mathbb{R}^D \rightarrow \mathbb{R}^D$
- 目标: $s_{\theta}(\mathbf{x}) \approx \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$

¹³ 图片来自清华叉院 Deep Learning 2025 Spring 公开课

¹⁴ Song Y, Ermon S. "Generative Modeling by Estimating Gradients of the Data Distribution." NeurIPS 2019, <https://arxiv.org/abs/1907.05600>.

① Diffusion Model

② Flow Matching

③ Score-Based Model

Energy-Based Model

模型简述

Score-based Generative Modeling 及其问题

NCSN

相关应用

Score Matching

分数匹配最初是为了基于未知数据分布的独立同分布样本学习非标准化统计模型而设计的。我们将其重新用于得分估计。借助分数匹配，我们可以直接训练得分网络 $\mathbf{s}_\theta(\mathbf{x})$ 来估计

$\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ ，而无需先训练模型来估计 $p_{\text{data}}(\mathbf{x})$ 。选择目标函数

$$\frac{1}{2} \mathbb{E}_{p_{\text{data}}} [\|\mathbf{s}_\theta(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})\|_2^2]$$

，可以证明，在相差一个常数的情况下，其等价于：

$$\mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[\text{tr}(\nabla_{\mathbf{x}} \mathbf{s}_\theta(\mathbf{x})) + \frac{1}{2} \|\mathbf{s}_\theta(\mathbf{x})\|_2^2 \right]$$

其中， $\nabla_{\mathbf{x}} \mathbf{s}_\theta(\mathbf{x})$ 表示 $\mathbf{s}_\theta(\mathbf{x})$ 的 Jacobian 矩阵。如果数据维度较大，会比较难以计算。

去噪分数匹配 (Denoising score matching)

去噪分数匹配避开了 $\text{tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\theta}(\mathbf{x}))$ 的计算。

它首先用预先指定的噪声分布 $q_{\sigma}(\tilde{\mathbf{x}} | \mathbf{x})$ 扰动数据点 $\mathbf{x}$ ，然后使用得分匹配来估计扰动后数据分布

$q_{\sigma}(\tilde{\mathbf{x}}) \triangleq \int q_{\sigma}(\tilde{\mathbf{x}} | \mathbf{x}) p_{\text{data}}(\mathbf{x}) d\mathbf{x}$ 的得分。该目标已被证明等价于：

$$\frac{1}{2} \mathbb{E}_{q_{\sigma}(\tilde{\mathbf{x}} | \mathbf{x}) p_{\text{data}}(\mathbf{x})} [\|\mathbf{s}_{\theta}(\tilde{\mathbf{x}}) - \nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}} | \mathbf{x})\|_2^2]$$

使上式最小化的最优分数网络（记为 $\mathbf{s}_{\theta^*}(\mathbf{x})$ ）几乎必然满足 $\mathbf{s}_{\theta^*}(\mathbf{x}) = \nabla_{\mathbf{x}} \log q_{\sigma}(\mathbf{x})$ 。但是只有当噪声足够小，使得 $q_{\sigma}(\mathbf{x}) \approx p_{\text{data}}(\mathbf{x})$ 时，才有

$$\mathbf{s}_{\theta^*}(\mathbf{x}) = \nabla_{\mathbf{x}} \log q_{\sigma}(\mathbf{x}) \approx \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$$

成立。

Sliced score matching

切片得分匹配使用随机投影来近似得分匹配中的 $\text{tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\theta}(\mathbf{x}))$ 。
其目标为：

$$\mathbb{E}_{p_{\mathbf{v}}} \mathbb{E}_{p_{\text{data}}} \left[\mathbf{v}^{\top} \nabla_{\mathbf{x}} \mathbf{s}_{\theta}(\mathbf{x}) \mathbf{v} + \frac{1}{2} \|\mathbf{s}_{\theta}(\mathbf{x})\|_2^2 \right]$$

其中， $p_{\mathbf{v}}$ 是随机向量的简单分布，例如多元标准正态分布。项 $\mathbf{v}^{\top} \nabla_{\mathbf{x}} \mathbf{s}_{\theta}(\mathbf{x}) \mathbf{v}$ 可以通过前向模式自动微分高效计算。与估计扰动数据得分的去噪得分匹配不同，切片得分匹配为原始未扰动的数据分布提供得分估计，但由于前向模式自动微分，其计算量大约是前者的四倍。

Langevin dynamics

朗之万动力学(Langevin dynamics) 仅利用得分函数 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 就能从概率密度 $p(\mathbf{x})$ 生成样本。给定固定步长 $\epsilon > 0$, 以及初始值 $\tilde{\mathbf{x}}_0 \sim \pi(\mathbf{x})$ (π 是先验分布), Langevin 方法即通过下式迭代计算:

$$\tilde{\mathbf{x}}_t = \tilde{\mathbf{x}}_{t-1} + \frac{\epsilon}{2} \nabla_{\mathbf{x}} \log p(\tilde{\mathbf{x}}_{t-1}) + \sqrt{\epsilon} \mathbf{z}_t, \mathbf{z}_t \sim \mathcal{N}(0, I)$$

当 $\epsilon \rightarrow 0$ 且 $T \rightarrow \infty$ 时, 可近似认为 $\tilde{\mathbf{x}}_T$ 是服从于 $p(\mathbf{x})$ 的样本。特别地, 进行 Langevin 采样依赖得分函数 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 。为了从 $p_{\text{data}}(\mathbf{x})$ 中获取样本, 我们可以先训练得分网络, 使得 $s_{\theta}(\mathbf{x}) \approx \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$, 然后利用 $s_{\theta}(\mathbf{x})$ 通过 Langevin 动力学近似获取样本。这就是**基于分数的生成式建模**(score-based generative modeling) 框架的核心思想。

Score-based Generative Modeling 的操作流程

Score-based generative modeling




图 25: Score-based Generative Modeling 的操作流程

Score-based Generative Modeling 的问题

问题 1: 在流形假设 (Manifold hypothesis) 下, 真实世界的数据是分布在一个低维流形上的, 分数如何定义?




图 26: 流形假设




图 27: 梯度难以定义

- 如右图, 在环的边界上难以定义 score function

Score-based Generative Modeling 的问题

问题 2: 低数据密度区域应当如何计算分数?




图 28: 分数密度问题




图 29: (a) 精准采样
(b) Langevin 动力学采样
(c) 退火 Langevin 动力学采样

- 在数据密度低的区域，由于缺乏数据样本，分数匹配可能没有足够数据来准确估计分数函数；
- Langevin 动力学采样可能无法在合理时间内收敛到真实分布（权重问题）

① Diffusion Model

② Flow Matching

③ Score-Based Model

Energy-Based Model

模型简述

Score-based Generative Modeling 及其问题

NCSN

相关应用

噪声条件分数网络(Noise Conditional Score Networks) 通过用随机高斯噪声扰动数据，以使得数据分布更便于基于分数的生成建模。




图 30: 流形上加噪示意图




图 31: 加噪之后的分布图象

对比实验




图 32: 有关加噪的对比实验

切片分数匹配 (SSM) 在 CIFAR 数据集上损失随迭代次数的变化

- 左图：未向数据添加噪声；
- 右图：对数据加以 $\mathcal{N}(0, 0.0001)$ 的扰动

如何平衡噪声大小？

- 大噪声能覆盖更多低密度区域，从而更好地进行得分估计；但它也会过度破坏数据，使数据与原始分布产生显著偏差。
- 小噪声对原始数据分布的破坏较小，但也无法覆盖低密度区域。

为了在这两方面取得最佳平衡，论文同时使用多尺度噪声扰动：

- 1 使用不同水平的噪声扰动数据；
- 2 训练单个条件得分网络，同时估计对应所有噪声水平的分数。

训练完成后，在使用 Langevin 动力学采样时，我们最初使用对应大噪声的得分，然后逐渐降低噪声水平进行退火。这有助于将大噪声水平的优势平滑地传递到低噪声水平，此时受扰动的数据与原始数据几乎无法区分。

NCSN 的定义

设 $\{\sigma_i\}_{i=1}^L$ 为正等比数列, 满足 $\frac{\sigma_1}{\sigma_2} = \dots = \frac{\sigma_{L-1}}{\sigma_L} > 1$ 。令

$q_\sigma(\mathbf{x}) \triangleq \int p_{\text{data}}(\mathbf{t}) \mathcal{N}(\mathbf{x} | \mathbf{t}, \sigma^2 I) d\mathbf{t}$ 表示受扰动数据分布。我们选择噪声水平 $\{\sigma_i\}_{i=1}^L$, 使得 σ_1 足够大以覆盖足够的区域, 且 σ_L 足够小以最小化对数据的影响。

$$\sigma_1 > \sigma_2 > \dots > \sigma_{L-1} > \sigma_L$$



图 33: 扰动序列示意图

我们的目标是训练一个条件分数网络, 以联合估计所有受扰动数据分布的分数, 即对任意 $\sigma \in \{\sigma_i\}_{i=1}^L$, 有

$\mathbf{s}_\theta(\mathbf{x}, \sigma) \approx \nabla_{\mathbf{x}} \log q_\sigma(\mathbf{x})$ 。注意, 当 $\mathbf{x} \in \mathbb{R}^D$ 时, $\mathbf{s}_\theta(\mathbf{x}, \sigma) \in \mathbb{R}^D$ 。

我们将 $\mathbf{s}_\theta(\mathbf{x}, \sigma)$ 称**噪声条件得分网络**(Noise Conditional Score Network, NCSN)

如何训练 NCSN?

论文中采用速度更快的去噪分数匹配：选择噪声分布为 $q_\sigma(\tilde{\mathbf{x}} | \mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}} | \mathbf{x}, \sigma^2 I)$ ；因此， $\nabla_{\tilde{\mathbf{x}}} \log q_\sigma(\tilde{\mathbf{x}} | \mathbf{x}) = -\frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma^2}$ 。对于给定的 σ ，去噪分数匹配目标为：

$$\ell(\boldsymbol{\theta}; \sigma) \triangleq \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathbb{E}_{\tilde{\mathbf{x}} \sim \mathcal{N}(\mathbf{x}, \sigma^2 I)} \left\| \mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}}, \sigma) + \frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma^2} \right\|_2^2$$

然后，我们针对所有 $\sigma \in \{\sigma_i\}_{i=1}^L$ 结合上面式子，得到一个统一的目标函数：

$$\mathcal{L}(\boldsymbol{\theta}; \{\sigma_i\}_{i=1}^L) \triangleq \frac{1}{L} \sum_{i=1}^L \lambda(\sigma_i) \ell(\boldsymbol{\theta}; \sigma_i)$$

其中， $\lambda(\sigma_i) > 0$ 是依赖于 σ_i 的系数函数。假设 $\mathbf{s}_{\boldsymbol{\theta}(\mathbf{x}, \sigma)}$ 有足够的容量，当且仅当对所有 $i \in \{1, 2, \dots, L\}$ ，几乎必然有 $\mathbf{s}_{\boldsymbol{\theta}^*}(\mathbf{x}, \sigma_i) = \nabla_{\mathbf{x}} \log q_{\sigma_i}(\mathbf{x})$ 时， $\mathbf{s}_{\boldsymbol{\theta}^*}(\mathbf{x}, \sigma)$ 能最小化式 (6)，因为式 (6) 是 L 个去噪得分匹配目标的凸组合。

如何训练

$\lambda(\cdot)$ 有很多可能的选择。理想情况下, 我们希望对于所有 $\{\sigma_i\}_{i=1}^L$, $\lambda(\sigma_i)\ell(\boldsymbol{\theta}; \sigma_i)$ 的值大致处于相同的数量级。从经验上看, 我们观察到当得分网络被训练到最优时, $\|\mathbf{s}_{\boldsymbol{\theta}(\mathbf{x}, \sigma)}\|_2 \propto 1/\sigma$ 。这启发我们选择 $\lambda(\sigma) = \sigma^2$ 。因为在这种选择下, 我们有

$$\lambda(\sigma)\ell(\boldsymbol{\theta}; \sigma) = \sigma^2\ell(\boldsymbol{\theta}; \sigma) = \frac{1}{2}\mathbb{E} \left\| \sigma \mathbf{s}_{\boldsymbol{\theta}(\tilde{\mathbf{x}}, \sigma) + \frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma}} \right\|_2^2$$

由于 $\frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma} \sim \mathcal{N}(0, I)$ 且 $\|\sigma \mathbf{s}_{\boldsymbol{\theta}(\mathbf{x}, \sigma)}\|_2 \propto 1$, 我们可以轻松得出 $\lambda(\sigma)\ell(\boldsymbol{\theta}; \sigma)$ 的数量级不依赖于 σ 的结论。

我们强调, 我们的目标函数式 (6) 不需要对抗训练, 不需要替代损失, 训练期间也不需要从得分网络进行采样 (比如, 不同于对比散度)。而且, 它也不需要 $\mathbf{s}_{\boldsymbol{\theta}(\mathbf{x}, \sigma)}$ 为了可处理而采用特殊架构。此外, 当 $\lambda(\cdot)$ 和 $\{\sigma_i\}_{i=1}^L$ 固定时, 它可用于定量比较不同的噪声条件得分网络 (NCSNs)。

NCSN 结合退火 Langevin 动力学做推理

Algorithm 1 Annealed Langevin dynamics.**Require:** $\{\sigma_i\}_{i=1}^L, \epsilon, T$.

- 1: Initialize $\tilde{\mathbf{x}}_0$
- 2: **for** $i \leftarrow 1$ to L **do**
- 3: $\alpha_i \leftarrow \epsilon \cdot \sigma_i^2 / \sigma_L^2$ $\triangleright \alpha_i$ is the step size.
- 4: **for** $t \leftarrow 1$ to T **do**
- 5: Draw $\mathbf{z}_t \sim \mathcal{N}(0, I)$
- 6: $\tilde{\mathbf{x}}_t \leftarrow \tilde{\mathbf{x}}_{t-1} + \frac{\alpha_i}{2} \mathbf{s}_\theta(\tilde{\mathbf{x}}_{t-1}, \sigma_i) + \sqrt{\alpha_i} \mathbf{z}_t$
- 7: **end for**
- 8: $\tilde{\mathbf{x}}_0 \leftarrow \tilde{\mathbf{x}}_T$
- 9: **end for**
- return** $\tilde{\mathbf{x}}_T$

图 34: 退火 Langevin 动力学采样

NCSN 结合退火 Langevin 动力学做推理

在训练好噪声条件得分网络 $s_\theta(\mathbf{x}, \sigma)$ 后，受模拟退火 [30] 和退火重要性采样 [37] 的启发，我们提出一种采样方法——退火朗之万动力学（算法 1）——来生成样本。如算法 1 所示，我们通过从某个固定先验分布（例如，均匀噪声）初始化样本来启动退火朗之万动力学。然后，我们以步长 α_1 运行朗之万动力学，从 $q_{\sigma_1}(\mathbf{x})$ 中采样。接下来，以上一次模拟得到的最终样本为起点，使用减小后的步长 α_2 ，运行朗之万动力学从 $q_{\sigma_2}(\mathbf{x})$ 中采样。我们继续以这种方式进行，将针对 $q_{\sigma_{i-1}}(\mathbf{x})$ 运行朗之万动力学得到的最终样本，作为针对 $q_{\sigma_i}(\mathbf{x})$ 运行朗之万动力学的初始样本，并按 $\alpha_i = \epsilon \cdot \sigma_i^2 / \sigma_L^2$ 逐渐减小步长 α_i 。最后，我们运行朗之万动力学从 $q_{\sigma_L}(\mathbf{x})$ 中采样，当 $\sigma_L \approx 0$ 时， $q_{\sigma_L}(\mathbf{x})$ 接近 $p_{\text{data}}(\mathbf{x})$ 。

NCSN 结合退火 Langevin 动力学做推理

由于分布 $\{q_{\sigma_i}\}_{i=1}^L$ 均受高斯噪声扰动，它们的支撑集覆盖整个空间，且其得分有明确定义，避免了流形假设带来的难题。当 σ_1 足够大时， $q_{\sigma_1}(\mathbf{x})$ 的低密度区域会变小，众数的孤立程度也会降低。如前所述，这会使得分估计更准确，朗之万动力学的混合速度更快。因此，我们可以认为朗之万动力学能为 $q_{\sigma_1}(\mathbf{x})$ 生成良好的样本。这些样本很可能来自 $q_{\sigma_1}(\mathbf{x})$ 的高密度区域，这意味着，鉴于 $q_{\sigma_1}(\mathbf{x})$ 和 $q_{\sigma_2}(\mathbf{x})$ 彼此仅有细微差异，它们也很可能位于 $q_{\sigma_2}(\mathbf{x})$ 的高密度区域。由于得分估计和朗之万动力学在高密度区域表现更优，来自 $q_{\sigma_1}(\mathbf{x})$ 的样本将作为针对 $q_{\sigma_2}(\mathbf{x})$ 运行朗之万动力学的良好初始样本。类似地， $q_{\sigma_{i-1}}(\mathbf{x})$ 为 $q_{\sigma_i}(\mathbf{x})$ 提供良好的初始样本，最终我们从 $q_{\sigma_L}(\mathbf{x})$ 中得到高质量样本。

① Diffusion Model

② Flow Matching

③ Score-Based Model

Energy-Based Model

模型简述

Score-based Generative Modeling 及其问题

NCSN

相关应用

用 Beamer 很高大上？

1111

Thanks!